

딥러닝 기반 은하 분류 교육 콘텐츠 개발

조훈^{1,2}, 손정주^{1*}

1. 한국교원대학교 지구과학교육과, 충청북도 청주시 28173

2. 충북과학기술혁신원, 충청북도 청주시 28126

Development of Deep Learning-Based Instructional Content for Galaxy Classification

Hun Cho^{1,2}, Jungjoo Sohn^{1*}

1. Korea National University of Education, Cheongju 28173

2. Chungbuk Innovation Institute of Science & Technology, Cheongju 28126

요약

본 연구의 목적은 고등학교 지구과학 교육과정의 은하 분류 단원을 중심으로, 실제 천문학 연구 절차를 반영한 딥러닝-데이터 사이언스 기반 교육 콘텐츠를 개발하고 그 교육적 적용 가능성을 탐색하는 데 있다. 본 연구에서는 지구과학 교사 및 예비교사가 프로그래밍 지식에 크게 의존하지 않고 수업에 적용할 수 있도록 웹 기반 앱과 활동지를 개발하였다. 특히 기존의 직관적 비교 활동이나 블랙박스형 AI 결과 확인 중심 활동의 제한점을 보완하기 위해, 지구과학 내용에 더해 데이터 사이언스 절차 및 데이터 리터러시를 반영하고 합성곱 신경망(CNN) 기반 분류 활동을 학습 과정에 구조화하였다. 천문학 전공 교수 및 현직 지구과학 교사를 대상으로 파일럿 테스트를 실시한 결과, 교육과정 적합성, 탐구 활동의 과학적 적절성, 데이터 리터러시 요소의 기여도에서 긍정적인 평가가 나타났다. 반면, 실용성과 기술적 안정성은 상대적으로 낮게 평가되었으며, 이에 대한 개선 의견을 반영하여 실행 방식과 이미지 로딩 방식을 보완하였다. 본 연구는 AI를 은하의 형태학적 특징과 분류 결과를 해석하는 탐구 도구로 활용함으로써, 2022 개정 교육과정에서 강조하는 데이터 기반 탐구를 지구과학 수업에서 구현할 수 있는 교육 콘텐츠 사례를 제시했다는 점에서 의의가 있다.

주제어: 딥러닝, 데이터 사이언스, 데이터 리터러시, 천문 교육, 교육 콘텐츠

ABSTRACT

This study developed deep learning- and data science-based instructional content for galaxy classification in high school Earth science and examined its educational applicability. A web-based application and worksheet were designed to support in-service and pre-service teachers with limited programming knowledge. The content integrated data science processes, data literacy, and CNN-based classification beyond simple image comparison or black-box AI use. A pilot test showed positive evaluations of curriculum alignment, scientific appropriateness, and data literacy, while lower-rated practicality and technical stability were addressed through improvements to the execution and image-loading methods. The study presents AI as an inquiry tool for interpreting galaxy morphology and classification results.

Key words: Deep Learning, Data Science, Data Literacy, Astronomy Education, Instructional Content

* 교신저자 이메일주소: jjsohn@knue.ac.kr

서론

데이터 사이언스(Data Science)는 문제 해결과 의사결정을 위해 컴퓨터 과학, 수학·통계, 과학적 방법론 등을 활용하는 다학제적 분야로 논의되어 왔다(김재경과 손의성, 2021; Cleveland, 2001; Dhar, 2013). 데이터 사이언스는 기계학습, 딥러닝, 빅데이터, 데이터 마이닝 등과 연계되며(김태영 외, 2020), 교육 분야에서는 데이터의 수집·분석·해석 능력과 관련된 다(문현우와 이영준, 2024; 한신과 김형범, 2019). 데이터 리터러시는 실제 맥락에서 데이터를 해석하고 평가하는 능력으로, 양적 추론, 데이터 사이언스에 대한 이해, 실제 맥락의 고려를 포함하며(Kjelvik & Schultheis, 2019), 2022 개정 교육과정에서도 과학 교과에서 실제 데이터를 활용한 데이터 기반 탐구가 강조되고 있다(교육부, 2022).

천문학은 대규모 관측 자료를 바탕으로 천체의 구조와 진화 과정을 해석하는 학문으로, 데이터 분석과 해석 기술이 중요하게 활용된다(조훈과 손정주, 2022a; 조훈과 손정주, 2025; Mickaelian, 2018). 은하 분류는 천문학 연구에서 오랫동안 다루어진 형태 분류 문제 중 하나이며(Rodríguez et al., 2022), Hubble(1936)의 분류 체계에서는 은하의 외형적 특징을 바탕으로 유형을 구분하는 기준을 제시하였다. 이후 은하 형태 분류는 세부 구조와 형태 요소를 포함하는 방향으로 확장되어 왔다. 최근에는 딥러닝 기반 AI를 활용하여 대규모 은하 이미지를 분류하고, 분류 정확도와 처리 효율을 높이려는 연구가 이루어지고 있으며(Chauhan & Singh, 2018; Wu et al., 2022), 개방형 천문 데이터의 활용이 확대되면서 천문 교육과 인공지능(Artificial Intelligence, AI) 활용 교육에 대한 논의도 이어지고 있다(조연수, 2022).

학교 교육에서 은하 분류는 주로 은하 사진을 비교하고 허블 분류 체계에 따라 유형을 구분하는 활동으로 다루어져 왔다. 2015 개정 교육과정의 지구과학 I에서는 일부 은하 사진을 활용한 핸드온(Hands-on) 방식의 분류 활동이 중심이었다(교육부, 2015). 이러한 활동은 은하의 형태 차이를 직관적으로 이해하는 데 유용하지만, 대량의 관측 자료 처리 과정이나 분류 결과의 불확실성을 다루기에는 제한이 있다. 컴퓨터를 활용한 은하 분류 교육도 국내외에서 시도되어 왔으나(조훈과 손정주, 2022b; Borne, 2009; Hart et al., 2016; Raddick et al., 2019), 대체로 정면 은하 사진의 기초적 분류 활동에 초점을 두어 데이터 처리 과정과 대용량 학습의 효과를 충분히 다루기에는 한계가 있었다(조연수, 2022). 이러한 흐름에 따라 2022 개정 교육과정은 지구과학 교수·학습에서 다양한 디지털 도구와 공공 자료를 활용한 자료 수집·처리 기회를 강조하고, ‘빅데이터와 인공지능을 이용하여 은하 분류하기’를 탐구 활동으로 제시하였다(교육부, 2022). 현재 고등학교 지구과학 탐구활동에서는 공공 데이터베이스의 은하 이미지를 수집하고 AI 도구로 분류하는 활동을 다루고 있다(오피셜 외, 2024; 이기영 외, 2024). 그러나 이러한 탐구활동은 주로 이미지 수집과 AI 분류 결과 확인에 초점을 두고 있어, 딥러닝 기반 데이터 처리 과정을 학습자가 충분히 경험하기에는 제한이 있다.

AI 기반 은하 분류 활동은 학생의 프로그래밍 수준과 학교 수업 환경을 고려하여, 티처블 머신(Teachable Machine)과 같은 시각적 인터페이스 기반 플랫폼을 활용하는 방식으로 제시되어 왔다(문우중 외, 2023; 신요한, 2022). 이러한 플랫폼은 접근성이 높고 수업에 적용하기 쉬우며 AI 분류 결과를 직관적으로 확인할 수 있다는 장점이 있다. 그러나 본 연구에서 다루고자 하는 데이터 전처리, 데이터 증강, 해상도 조절, 모델 구조 조정 등 딥러닝 기반 데이터 처리 과정을 학습자가 직접 확인하거나 조정하는 데에는 제한이 있다. 따라서 AI 기반 은하 분류 활동은 단순한 분류 결과 확인을 넘어, 데이터 처리 조건이 분류 결과에 미치는 영향과 오분류 사례를 은하 형태 판별 기준과 연결하여 해석하도록 구성될 필요가 있다.

이에 본 연구는 고등학교 지구과학 교육과정의 은하 분류 단원을 대상으로, 기술 구현의 부담을 낮추면서 데이터 처리 조건과 분류 결과 해석을 다룰 수 있는 딥러닝 기반 교육 콘텐츠를 개발하고자 하였다. 본 연구에서는 AI를 은하의 형태학적 특징을 식별하고 분류 결과를 해석하는 탐구 도구로 설정하고, 데이터 리터러시와 데이터 사이언스 절차를 수업 구조에 반영하였다. 그리고 이를 바탕으로 합성곱 신경망(Convolutional Neural Network, CNN) 기반 데이터 증강, 해상도 조절, 혼동행렬 및 오분류 사례 분석을 포함한 웹(Web) 기반 앱(App)과 활동지를 개발하였으며, 지구과학 교사 및 예비교사의 수업 적용 가능성을 검토하였다.

이론적 배경

교육과정과 천문학·우주과학 분야에서의 은하 분류

천문학은 관측 자료를 바탕으로 천체의 구조와 진화 과정을 해석하는 학문으로, 자료의 분석과 해석이 중요한 역할을 한다(조훈과 손정주, 2022a; Mickaelian, 2018). 은하 분류는 천문학에서 오랫동안 다루어진 형태 분류 문제 중 하나이며(Rodríguez et al., 2022), Hubble(1936)의 형태 분류 체계는 타원 은하, 나선 은하, 막대 나선 은하, 불규칙 은하 등 은하의 외형적 특징을 구분하는 기준을 제시하였다. 이후 de Vaucouleurs(1963)의 분류 체계에서는 나선팔의 조임 정도, 막대 구조, 고리 구조 등 세부 형태 요소가 확장되어 논의되어 왔다(조훈과 손정주, 2022b). 천문학에서 은하 형태 분류는 외형적 구분에 그치지 않고, 은하의 물리적 성질과 진화 과정을 해석하는 자료로 활용된다(Buta, 2013).

학교 교육과정에서 은하 분류는 허블 분류 체계를 바탕으로 은하 사진을 비교하고 유형을 구분하는 활동으로 다루어져 왔다. 2015 개정 교육과정의 지구과학 I에서는 일부 은하 사진을 비교하는 핸드온 방식의 분류 활동이 중심이었다(교육부, 2015). 이러한 활동은 은하의 형태 차이를 직관적으로 이해하는 데 유용하지만, 대량의 관측 자료 처리나 분류 결과의 불확실성을 다루기에는 제한이 있다. 2022 개정 교육과정의 지구과학에서는 공공 천문 데이터베이스의 은하 이미지를 수집하고 AI 도구로 분류하는 ‘빅데이터와 인공지능을 이용하여 은하 분류하기’ 탐구 활동이 제시되었다(교육부, 2022). 이와 관련하여 현재 고등학교 지구과학 교과서에서는 공공 데이터베이스의 은하 이미지를 수집하고 인공지능 도구로 분류하는 활동을 다루고 있다(오필석 외, 2024; 이기영 외, 2024).

천문학·우주과학 분야에서는 딥러닝 기반 AI를 활용하여 대규모 은하 이미지를 분류하고, 분류 정확도와 처리 효율을 높이려는 연구가 이루어져 왔다(Chauhan & Singh, 2018; Wu et al., 2022). 이러한 연구에서는 이미지 수집, 전처리, 데이터 증강, 모델 학습, 성능 평가 등 데이터 처리 절차가 함께 다루어진다(Gharat & Dandawate, 2022; Wu et al., 2022). 반면 학교 현장의 AI 활용 은하 분류 활동은 학생의 프로그래밍 수준과 수업 환경을 고려하여 티쳐블 머신과 같은 시각적 인터페이스 기반 플랫폼을 활용하는 경우가 많다(문우종 외, 2023; 신요한, 2022). 이러한 플랫폼은 접근성과 수업 적용 가능성이 높다는 장점이 있으나, 데이터 전처리, 데이터 증강, 모델 구조, 오분류 해석과 같은 세부 절차를 충분히 드러내기에는 제한이 있다.

딥러닝 기반 은하 이미지 분류와 지구과학적 해석

AI는 데이터에 기반하여 분석·예측·추론을 수행하는 기술로, 여러 분야에서 활용되고 있다(김주은, 2019; 문우종 외, 2023). 딥러닝은 데이터에서 특징을 학습하는 기계학습 방식으로, 패턴 인식과 이미지 분류 문제에 적용된다. 은하 이미지 분류에서는 중심부, 막대 구조, 나선팔, 외곽 윤곽 등 형태 정보를 바탕으로 은하 유형을 구분하므로, CNN 기반 접근이 활용되어 왔다(Gharat & Dandawate, 2022; Wu et al., 2022).

CNN은 이미지의 국소 영역에서 특징을 추출하고, 풀링(Pooling) 과정을 통해 특징 정보를 압축하여 분류에 활용하는 모델이다. 은하 이미지에서는 핵, 막대, 나선팔, 외곽 윤곽 등 형태학적 특징을 학습하는 데 사용될 수 있다. 따라서 지구과학 교육에서 CNN은 딥러닝 기술 자체의 학습 대상이라기보다, 은하의 관측적 특징과 분류 결과를 해석하는 도구로 다루어질 수 있다.

천문 이미지 분류에서 데이터 증강과 해상도는 모델 결과 해석과 관련된다. 회전 및 대칭 증강은 CNN의 데이터 훈련 시 형태 변이를 늘려 과적합을 줄이는 데 활용되며, 은하 형태 분류에서는 은하가 하늘 평면상에서 다양한 방향으로 관측

된다는 점을 고려할 때 회전 대칭성 또는 회전 불변성과도 관련된다(Dieleman et al., 2015).

해상도 역시 은하 형태 판별에 영향을 미친다. 이미지 해상도가 낮아지면 막대 구조, 나선팔, 외곽 윤곽과 같은 세부 형태가 흐려지거나 소실되어 모델이 은하 형태를 잘못 분류할 가능성이 높아진다. 이와 같은 해상도 문제는 AI 모델의 분류 과정에만 해당하는 것이 아니라, 실제 은하 형태 분류에서도 관측 이미지의 해상도와 노출 깊이가 분류에 활용 가능한 형태 정보를 좌우한다는 점에서 중요하게 논의되어 왔다(Buta, 2013).

딥러닝 모델의 성능은 정확도, 손실 값, 혼동행렬 등을 통해 평가된다. 혼동행렬은 실제 유형과 예측 유형의 관계를 제시하여, 어떤 은하 유형 사이에서 분류 혼동이 나타나는지 확인하게 한다. 정확도는 전체 분류 성능을 요약하는 지표이나, 클래스 구성이나 특성 유사성에 따라 결과 해석에 제한이 있을 수 있기에(이지훈과 신지은, 2024), 딥러닝 은하 분류에서는 정확도와 혼동행렬이 함께 사용된다.

데이터 사이언스와 데이터 리터러시 기반 디지털 탐구

데이터 사이언스는 데이터를 바탕으로 현상을 이해하고 문제 해결과 의사결정에 필요한 지식을 도출하는 분석적 접근이다(Cleveland, 2001; Dhar, 2013). 이는 기계학습, 딥러닝, 빅데이터, 데이터 마이닝 등과 연계되고(김태영 외, 2020), 교육 분야에서는 데이터의 수집·분석·해석 능력과 관련되며(문현우와 이영준, 2024; 한신과 김형범, 2019), 2022 개정 교육과정에서도 과학 교과에서 실제 데이터를 다루는 데이터 기반 탐구가 강조되고 있다(교육부, 2022).

본 연구는 구덕회와 김동진(2020)이 제안한 데이터 사이언스 절차를 기본 틀로 삼되, 은하 이미지 자료의 특성을 고려하여 일부 단계를 조정하였다. 수집된 이미지 자료는 분석에 적합한 형태로 정제·가공할 필요가 있으므로 데이터 처리 단계를 포함하였고(교육부와 한국과학창의재단, 2021), 데이터의 구조와 패턴을 사전에 확인하기 위해 데이터 탐색 단계를 반영하였다(양병화, 2013; Tukey, 1977). 반면, 데이터 사이언스 절차 자체에 대한 평가는 연구 목적과 범위에 따라 제외하였다. 이에 따라 본 연구에서는 문제 정의, 데이터 수집, 데이터 처리, 데이터 탐색, 데이터 분석 및 표현, 일반화의 여섯 단계로 절차를 구성하였다.

문제 정의는 해결할 문제를 명확히 하거나 목표 또는 가설을 설정하는 단계이며(김용민과 김종훈, 2017), 데이터 수집은 필요한 데이터의 속성, 대상, 출처를 확인하고 데이터를 확보하는 과정이다(김화중, 2014; 하수옥과 정의현, 2020). 데이터 처리는 분석에 적합하도록 데이터를 정제·가공하는 단계이고(교육부와 한국과학창의재단, 2021; 하수옥과 정의현, 2020), 데이터 탐색은 데이터의 구조와 패턴을 확인하는 과정이다(양병화, 2013; Tukey, 1977). 데이터 분석 및 표현은 데이터 간 관계를 파악하고 이를 분류·해석·시각화하는 단계이며(서용과 안성진, 2022; Calzada-Prado & Marzal, 2013), 일반화는 분석 결과를 바탕으로 문제에 대한 해석과 결론을 도출하는 단계이다(구덕회와 김동진, 2020).

데이터 리터러시는 실제 데이터를 통해 도출된 정보를 이해하고 평가하는 능력으로, 양적 추론, 데이터 사이언스에 대한 이해, 실제적 맥락의 고려를 포함한다(Kjelvik & Schultheis, 2019). 선행연구에서는 데이터 이해, 수집, 분석, 평가, 표현, 의사결정, 의사소통, 윤리적 활용 등이 주요 요소로 논의되어 왔다(배화순, 2019; 정윤숙과 유지원, 2022; 최경희와 조동성, 2023; 한상우, 2020; Athanases et al., 2013; Calzada-Prado & Marzal, 2013; Herzog, 2016). 본 연구는 이러한 논의를 바탕으로 데이터 이해, 데이터 분석 계획 및 수집, 데이터 분석, 데이터 평가, 데이터 도구 활용, 데이터 표현, 데이터 기반 의사결정, 데이터 기반 의사소통, 데이터 윤리를 데이터 리터러시 요소로 설정하였다.

과학교육에서 AI 활용과 관련하여, 교사의 수업 부담, 블랙박스형 도구 활용, 딥러닝 학습 과정의 교과 적합성에 관한 논의가 제기되어 왔다(문우중 외, 2023; 문현우와 이영준, 2024; 신요한, 2022). 이러한 논의는 AI 기반 은하 분류 활동을 기술 구현 중심으로 제시하기보다, 데이터를 다루고 해석하는 과정을 지구과학 탐구로 구조화할 필요성을 시사한다. 이 점에서 데이터 사이언스 절차는 탐구 수행의 구조를 제공하고, 데이터 리터러시는 데이터 기반 해석과 판단의 기준으로

표 1. 은하 이미지 분류 콘텐츠의 연구 절차

콘텐츠 개발					
개발 내용	적용 교육과정	적용 수준 (과목)	적용 단위	콘텐츠 활동 주제	
	2022	고등학교 (지구과학)	태양계 천체와 별과 우주의 진화	실제 은하 데이터를 활용한 AI 기반 은하 분류 탐구 - 딥러닝·데이터 사이언스 절차에 따른 분류 결과 해석과 판단 활동	
개발 방법	1단계 내용 체계 수립: 데이터 사이언스 절차에 따라 콘텐츠 활동 내용과 적용할 데이터 리터러시 요소 수립				
	2단계 프로토타입 타입 개발	- UI/UX 구성: 데이터 사이언스 6단계 반영, 단계별 질문과 힌트 제공 학습자 이해유도			
		- 데이터 수집: NED에서 은하 유형 확인 ⇒ CDS Portal 활용 SDSS-DSS 이미지 수집(일부 GALEX 이미지 활용)			
		레이블	주요 유형	세부 유형	데이터 개수
		Class0	타원	E0~E7	117
		Class1	렌즈	S0, SA0, SB0, SAB0	104
		Class2	정상 나선	SAa, SAb, SAc, SAd	123
		Class3	막대 나선	SBa, SBb, SBc, SBd	123
		Class4	불규칙	I	81
		합계			548
		- 데이터 전처리 자동화: 이미지 크기 표준화(50×50), 칼라·흑백 변환, 회전·대칭 증강(최대 16배)			
	- 데이터 탐색: 은하별 수량·특징·해상도 확인 및 처리 결과 시각화				
	- 데이터 분석 및 성능 평가: CNN 구조 설계, 정확도·손실 값 혼동행렬을 통한 성능 검증				
	※ 기능 구현의 유연성: 드롭아웃, 칼라·흑백 처리 보조 기능 구현 ⇒ 공개 소스의 교육적 활용성 확보				
	3단계 성능검증	① 정확도, 손실 값, 혼동행렬을 통해 모델의 일반화 성능 확인 ② 훈련 시간 10 분 이하의 수업 적용 가능성 확인 ③ 서로 다른 Seed에서의 반복 학습을 통한 데이터 증강 효과 및 모델 성능 안정성 확인			
	4단계 학습지 제작	(내용) AI 활용 은하 분류 과정 경험, 오분류 원인 분석을 통해 데이터 리터러시·데이터 사이언스·과학 탐구 역량 이해 (방법) 웹 앱 사용법 및 데이터 사이언스 절차에 따른 실험 구조화			
	5단계 파일럿 테스트	(5점 리커트 척도 정량평가) 개발된 앱의 교육적 타당성과 실용성에 대한 평가, (정성평가) 콘텐츠 개선사항 기술			

기능한다.

연구 방법

본 연구는 고등학교 지구과학의 은하 분류 단원에 적용할 수 있는 딥러닝 기반 교육 콘텐츠를 개발하고, 전문가 파일럿 테스트를 통해 수업 적용 가능성을 검토한 개발 연구이다. 연구 절차는 내용 체계 수립, 프로토타입 개발, 성능검증, 학습지 제작, 파일럿 테스트의 5단계로 구성하였다. 각 단계의 주요 내용은 표 1과 같다.

1단계: 내용 체계 수립

내용 체계는 2022 개정 교육과정의 ‘태양계 천체와 별과 우주의 진화’ 단원을 바탕으로 수립하였다. 데이터 사이언스 절차는 문제 정의, 데이터 수집, 데이터 처리, 데이터 탐색, 데이터 분석 및 표현, 일반화의 여섯 단계로 구성하였으며, 각 단계에 지구과학 탐구 중점, AI 활용 방식, 데이터 리터러시 요소, 수행 결과물을 대응시켰다(표 2). 문제 정의 단계에서는 AI 기반 은하 분류 탐구의 목표를 설정하고, 데이터 수집 단계에서는 NASA/IPAC 외부은하 데이터베이스(NASA/IPAC

표 2. 내용 체계 수립

단계	지구과학 탐구 중점	디지털 탐구 도구(AI)	데이터 리터러시 요소	수행 결과물
문제 정의	천문학적 분류의 주관성 및 불확실성 이해	지능형 분석 도구의 필요성 인식	데이터 분석 계획	탐구 질문 및 분석 목표 수립
데이터 수집	허블 분류 체계에 따른 형태학적 기준 확립	신뢰성 있는 천문 SDSS-DSS 및 일부 GALEX 이미지 확보	데이터 수집	원시 은하 이미지 데이터셋 확보
데이터 처리	관측 환경에 따른 외형 변화(방향성) 이해	관측 조건 재현 및 데이터 증강 실습	데이터 분석	정제·증강된 이미지 데이터셋 확보
데이터 탐색	은하 유형별 구조적 특징 및 분포 이해	전처리 결과의 시각적 확인 및 점검	데이터 이해, 데이터 분석	데이터 요약 보고 및 탐색 결과 확보
데이터 분석 및 표현	은하의 세부 구조 (핵, 막대, 나선팔) 정밀 식별	CNN 특징 추출 및 성능 지표 도출	데이터 표현, 데이터 평가, 데이터 기반 의사결정, 데이터 도구 활용	성능 지표 시각화 결과, 모델 성능 분석 보고
일반화	관측 조건이 결과의 불확실성에 미치는 영향 해석	AI 산출물에 대한 비판적 판단 및 의사결정	데이터 기반 의사소통, 데이터 윤리	탐구 활동 결과 보고

Extragalactic Database, NED)와 스트라스부르 천문자료센터(Centre de Données astronomiques de Strasbourg, CDS) Portal 등의 공공 천문 데이터베이스와 SDSS(Sloan Digital Sky Survey)와 DSS(Digitized Sky Survey) 및 일부 GALEX(Galaxy Evolution Explorer) 관측 이미지를 활용하여 은하 이미지 자료를 확보하도록 구성하였다. 데이터 처리와 탐색 단계에서는 이미지 표준화, 회전·대칭 증강, 데이터 분포 확인을 포함하였으며, 데이터 분석 및 표현과 일반화 단계에서는 CNN 기반 분류 결과와 혼동행렬, 오분류 사례를 해석하도록 구성하였다.

2단계: 프로토타입 개발

프로토타입은 학습 콘텐츠를 웹 환경에서 구현하기 위해 Streamlit 기반 웹 앱 형태로 개발하였다. 앱은 데이터 사이언스 절차에 따라 단계별 탭을 구성하고, 학습자가 은하 이미지 수집, 전처리, 탐색, CNN 기반 분류, 성능 평가를 순차적으로 수행할 수 있도록 설계하였다.

개발환경

콘텐츠의 개발 환경은 표 3과 같다. 운영체제는 Windows 11, 프로세서는 Intel i7-10750H, 메모리(RAM)는 32 GB이며, 별도의 GPU를 사용하지 않은 CPU 기반 로컬 PC 환경에서 개발 및 성능검증을 수행하였다. 주요 프로그래밍 언어는 Python 3.9, 딥러닝 프레임워크는 Keras를 사용하였다. 딥러닝 모델 구현, 시각화, 웹 애플리케이션 구동에는 Scikit-learn, TensorFlow, Streamlit을 활용하였다. 개발한 웹 애플리케이션과 활동지는 구글(Google) 사이트를 통해 배포하였다.

표 3. 개발환경

구분	내용	구분	내용
운영체제	Windows 11	메모리	32 GB
프로세서	Intel(R) Core(TM) i7-10750H CPU	GPU	미사용
주요 라이브러리	Scikit-learn, TensorFlow, Streamlit	프로그래밍 언어	Python 3.9
딥러닝 프레임워크	Keras	실행 환경	로컬 PC
앱 배포처	구글 사이트 https://zrr.kr/reeg6S		

사용자 친화적 UI/UX 설계

Streamlit 환경에서 내용 체계의 단계에 따라 탭을 구성하고, 각 단계에 탐구 질문과 ‘힌트 보기’ 기능을 배치하였다. 실습 결과는 실시간으로 시각화되도록 하였으며, 예측 정확도, 손실 값, 혼동행렬, 오분류 이미지를 확인할 수 있도록 구성하였다. 이를 통해 학습자가 딥러닝 모델의 학습 과정과 분류 결과를 단계별로 확인할 수 있도록 하였다.

데이터 수집

데이터 수집은 분류 기준 설정과 이미지 확보의 순서로 진행하였다. 은하 유형은 Hubble 계열의 형태 분류 체계와 NED의 형태 분류 정보를 참고하여 타원 은하, 렌즈 은하, 정상 나선 은하, 막대 나선 은하, 불규칙 은하의 5개 유형으로 구분하고 Class0~4로 레이블링하였다. 이후 CDS Portal 등을 활용하여 은하 형태 판별에 상대적으로 유리한 SDSS 이미지를 우선 수집하고, SDSS 이미지 확보가 어렵거나 형태 확인이 제한적인 경우 DSS 이미지를 보완적으로 활용하였다. 불규칙 은하의 일부는 GALEX 이미지를 활용하였다. 동일 천체가 데이터셋에 중복하여 포함되지 않도록 확인하였다. 본 연구에서는 교과서에서 주로 활용되는 형태가 명확한 대표 은하만을 선별하기보다 실제 천문 관측 자료의 다양성과 불확실성을 반영하고자 하였다. 이에 형태적 특징이 희미하거나 육안 판별이 다소 모호한 경우에도 NED에서 형태 유형이 분류된 천체는 해당 분류 정보를 기준으로 데이터셋에 포함하였다. 최종적으로 타원 은하 117개, 렌즈 은하 104개, 정상 나선 은하 123개, 막대 나선 은하 123개, 불규칙 은하 81개 등 총 548개의 이미지를 구성하였다. 수집된 이미지는 별도의 수동 크롭, 중심 재정렬 또는 배경 제어를 수행하지 않고 원자료의 관측 형태를 유지하였다.

데이터 전처리 자동화와 탐색

수집된 은하 이미지는 앱에서 은하 유형을 선택한 뒤 지정한 범위 내에서 불러올 수 있도록 구성하였다. 이후 이미지 크기를 50×50 픽셀로 표준화하고, 컬러 또는 흑백 이미지 선택, 45° 간격 회전과 좌우 대칭을 통한 데이터 증강이 자동으로 수행되도록 하였다. 회전과 대칭을 모두 적용할 경우 훈련 데이터는 최대 16배까지 증강할 수 있도록 하였다. 성능검증에서는 데이터 누수를 방지하기 위해 원본 데이터를 먼저 분할한 후 훈련 데이터에만 증강을 적용하였다. 전처리 결과는 실시간 시각화로 제시하여 이미지 표준화와 데이터 증강 결과를 단계별로 확인할 수 있도록 하였다.

데이터 분석 모델 설계 및 성능 평가

데이터 분석 단계에서는 CNN 기반 모델 구조를 바탕으로 하이퍼파라미터를 조정할 수 있도록 구성하였다. 실습자는 합성곱 레이어, 필터 수, 풀링 크기, 학습률 등 주요 설정을 조정하고, 학습 결과를 정확도, 손실 값, 혼동행렬, 오분류 이미지 등을 통해 확인할 수 있다. 또한 콜백(Callback) 기능으로 조기 종료(EarlyStopping)와 학습률 자동 조정(ReduceLROnPlateau)을 적용하여, 학습이 과도하게 반복되는 경우 조기 종료하고, 성능 개선이 정체되는 경우 학습률을 조정할 수 있도록 하였다.

공개소스 및 교육적 확장성 고려

본 연구의 코드는 비영리 교육 및 학술용 공개소스로 제공하였다. 사용자는 제공된 데이터셋 외에 새로운 은하 이미지를 추가하거나 기존 이미지를 교체하여 모델 학습에 활용할 수 있다. 또한 과학 탐구 활동, 자유탐구, 교사 연수 등에서

활용할 수 있도록 데이터 선택, 컬러·흑백 변환, 드롭아웃 적용 여부 등의 기능을 앱에 포함하였다. 일부 기능은 본 연구의 데이터셋에서 성능 차이가 크지 않았으나, 수업 상황에 따라 사용할 수 있도록 선택 기능으로 유지하였다.

3단계: 성능검증

성능검증은 수업 적용 가능성을 고려하여 훈련 시간, 정확도, 손실 값 및 혼동행렬을 기준으로 실시하였다. 모델 훈련 시간은 학교 수업에서 반복적인 모델 학습과 결과 해석에 소요되는 시간을 고려하여, CPU 기반 로컬 실행 환경에서 10 분 이내를 목표로 설정하였다. 그리고 데이터 누수를 방지하기 위해 원본 데이터를 훈련·검증·테스트 데이터셋으로 먼저 분할하고 데이터 증강은 훈련 데이터에만 적용하였다. 또한 학습 과정의 난수 조건에 따른 성능 변동을 확인하기 위해 5개의 무작위 시드(random seed; 12, 32, 42, 2024, 2026)를 적용하여 반복 학습하였다.

4단계: 학습지 제작

학습지는 다음과 같이 제작하였다. 학습자가 딥러닝을 과학적 탐구를 지원하는 분석 도구로 활용하며, 분류 결과의 한계와 불확실성을 비판적으로 해석할 수 있도록 하였다. 이를 위해 데이터 사이언스의 전 과정을 직접 수행함으로써 데이터 리터러시가 실제 과학 탐구에서 어떻게 작동하는지를 체험하고, 데이터 사이언스 기반 탐구의 의미를 이해하도록 구성하였다. 이때 학습지는 웹 앱의 흐름과 동일하게 구성하되, 단계별로 튜토리얼을 제시하여 앱 사용 방법을 쉽게 익힐 수 있도록 하였다. 단, 데이터 분석 단계의 세부 실험은 학교 현장의 제한된 수업 시수와 개인차를 고려하여 '필수 탐구'와 '심화 선택 탐구'로 이원화하였다. 이에 따라 데이터 처리와 모델 학습 조건을 다루는 '데이터 증강'과 '학습률' 실험은 필수로, 모델의 공학적 구조를 다루는 '모델 파라미터 규모'와 '최대 풀링 크기'는 심화 활동으로 제시하여 수업 운영의 유연성을 확보하였다.

5단계: 파일럿 테스트

개발된 웹 앱과 학습 활동지는 천문학 전공 교수 1명과 현직 지구과학 교사 4명을 대상으로 파일럿 테스트를 실시하였다. 현직 교사 4명은 모두 지구과학교육 전공자였고, 이 중 2명은 AI 융합교육을 추가 전공하였다. 교육 경력은 10년 이상 2명, 5년 이상 10년 미만 1명, 3년 이상 5년 미만 1명이었다.

정량 평가는 5점 리커트 척도 6문항으로 구성하였으며, 데이터 사이언스 절차의 논리성 및 수업 적용 가능성(Ceccucci et al., 2015), 교육과정 적합성(교육부, 2022), 육안 분류와 CNN 기반 분류 결과 해석의 과학적 타당성(Lehrer & Schauble, 2006), 데이터 리터러시 기여도(Kjelvik & Schultheis, 2019), 실용성과 기술적 안정성(Nielsen, 1994), AI 분류 결과의 한계와 불확실성을 과학적 근거에 따라 검토할 수 있는지를 평가하였다(Duschl, 2008; NRC, 2012). 정성 평가는 개선 의견과 제언을 수렴하는 방식으로 실시하였다.

연구 결과

성능검증 결과

표 4. 데이터 증강 여부에 따른 5개 Seed 반복 학습 테스트 성능

Seed	증강 테스트 정확도(%)	비증강 테스트 정확도(%)	증강 학습시간(초)
12	78.18	72.73	327.55
32	80.00	24.45	363.31
42	83.64	70.94	292.54
2024	83.64	27.27	449.17
2026	78.18	65.45	268.46
평균±표준편차	80.73±2.76	52.17±24.19	-

5개 은하 유형의 이미지는 50×50 픽셀의 컬러 이미지로 처리하였다. 총 548개의 원본 이미지를 훈련 438개, 검증 55개, 테스트 55개로 분할하였으며, 회전 및 대칭 증강은 훈련 데이터에만 적용하여 총 7,008개의 학습용 이미지를 구성하였다.

CNN 모델은 3개의 합성곱 레이어(32, 64, 128)와 2개의 완전 연결 레이어(128, 64)로 구성하였으며, 최대 풀링 크기는 2×2로 설정하였다. 배치 정규화(Batch Normalization), 전역 평균 풀링(Global Average Pooling), L2 정규화(L2 Regularization, 0.03)를 적용하였고, 은닉층에는 ReLU, 출력층에는 Softmax 함수를 사용하였다. 배치 크기는 16, 최대 에포크 수는 100, 학습률은 0.001로 설정하였으며, 모델 학습에는 Adam 최적화 알고리즘과 조기 종료 및 학습률 감소를 적용하였다.

5개의 Seed를 적용한 반복 학습 결과, 데이터 증강 조건의 테스트 정확도는 78.18~83.64 %, 평균 80.73±2.76 %였으며, 비증강 조건은 24.45~72.73 %, 평균 52.17±24.19 %로 나타났다(표 4). 모든 Seed에서 증강 조건의 정확도가 높았고 성능 변동도 상대적으로 작았으며, 학습 시간은 268~449 초로 모두 10 분 이내였다.

반복 학습 결과의 시각적 예시로 Seed 2024에서의 훈련·검증·테스트 정확도는 각각 97.52 %, 80.00 %, 83.64 %였으며, 손실 값은 0.3286, 0.7505, 0.8219였다(그림 1). 혼동행렬에서는 타원 은하와 렌즈 은하, 정상 나선 은하와 막대 나선 은하 등에서 일부 혼동이 나타났다. 이 중 그림 1C에는 테스트 데이터에서 확인된 9개의 오분류 사례 중 대표적인 5개를 제시하였다. 분석 결과, 타원 은하가 렌즈 은하로, 막대 나선 은하가 정상 나선 은하로, 정상 나선 은하가 막대 나선 은하 또는 렌즈 은하로, 불규칙 은하가 정상 나선 은하로 분류되는 사례가 확인되었다. 이러한 오분류는 이미지를 50×50 픽셀로 축소하는 과정에서 막대 구조와 나선팔 등 세부 형태 정보가 약화된 점, 실제 관측 자료에서 형태적 특징이 희미하거나 유형 간 경계가 모호한 은하를 NED의 형태 분류 정보를 기준으로 포함한 데이터셋의 특성과 관련된 것으로 해석된다.

파일럿 테스트 결과

전문가 파일럿 테스트 결과, 교육과정 적합성, 과학적 탐구 구성, 데이터 리터러시, AI 분류 결과의 해석 및 수업 활용 등 대부분의 평가 영역에서 긍정적인 평가가 나타났다(표 5). 이 중 육안 분류와 CNN 기반 분류 결과를 비교·해석하는 탐구 활동의 과학적 적절성이 5점으로 가장 높았으며, 실용성과 기술적 안정성은 3점으로 상대적으로 낮게 나타났다. 이러한 결과는 개발 콘텐츠의 초기 수업 적용 가능성을 확인한 것으로, 전문가 5명을 대상으로 한 파일럿 검토라는 점에서 실제 학생 대상 수업이나 일반적인 수업 상황에서의 교육적 효과로 확대하여 해석하는 데에는 한계가 있다.

개방형 응답에서는 CNN 개념 설명, 탐구 질문, 시스템 안정성에 관한 개선 의견이 제시되었다(표 6). 이에 따라 앱에 레이어, 노드, 필터 등 CNN의 주요 개념을 설명하는 튜토리얼을 추가하고, 활동지의 단계별 탐구 안내와 질문·힌트를 보완하였다. 또한 웹 기반 이미지 로딩 과정의 안정성을 개선하기 위해 이미지를 로컬 폴더에서 불러오도록 변경하고, 필수 라이브러리 설치와 앱 실행을 자동화하였다.




그림 1. Seed 2024에서의 모델 학습 및 분류 결과 (A) 훈련 및 검증 정확도 및 손실 값. (B) 테스트 정확도, 손실 값, 혼동행렬. (C) 테스트 데이터의 대표 오분류 이미지.

표 5. 파일럿 테스트 정량 평가 결과

번호	내용	평균	표준 편차	5점 (명)	4점 (명)	3점 (명)	2점 (명)	1점 (명)
1	데이터 사이언스 절차와 전체 활동 흐름이 교사가 이해하고 수업에 적용하기에 논리적으로 구성되어 있는가	4.80	0.45	4	1	0	0	0
2	은하 이미지 분류 활동이 허블 분류 체계 지도 및 교육과정 성취기준에 적절히 부합하는가	4.80	0.45	4	1	0	0	0
3	CNN 기반 분류와 육안 분류 결과를 비교·해석하는 탐구 활동이 과학적 탐구로서 의미 있게 구성되어 있는가	5.00	0.00	5	0	0	0	0
4	데이터 리터러시 요소가 교사의 데이터 기반 수업 설계 및 탐구 결과 해석에 기여하는가	4.00	0.71	1	3	1	0	0
5	콘텐츠가 실제 수업 현장에서 활용 가능한 실용성과 기술적 안정성을 갖추고 있는가	3.00	0.71	0	1	3	1	0
6	AI 분류 결과의 한계와 불확실성을 비판적 탐구로 확장할 수 있도록 설계되어 있는가	4.40	0.55	2	3	0	0	0

표 6. 파일럿 테스트 개선 요구사항 및 보완 결과

구분	개선 요구 사항 (전문가 의견)	보완 결과 (콘텐츠 반영 사항)
개념 설명 및 탐구 안내	학습 단계 간의 연결성 고려 및 CNN 모델, 하이퍼파라미터에 대한 친절한 사전 설명 필요	5단계, 앱 내에 CNN의 주요 개념을 비유적으로 설명하는 상세한 튜토리얼 가이드 추가 탑재 - 활동지 내 단계별 탐구 안내문 추가
탐구 질문의 직관성	육안 분류와 AI 분류의 차이 등 탐구 본질이 학습자 수준에서 직관적으로 와닿도록 질문 수정 필요	6단계, 육안 분류와 AI 분류의 차이, 오분류 발생의 과학적 원인 등에 대하여 학습자 수준에 맞추어 활동지와 앱 내 탐구 질문 및 힌트를 직관적인 어휘로 수정
시스템 실용성 및 안정성	네트워크 환경에 따른 웹 사용의 불편함 및 이미지 로딩 방식의 안정성 개선 필요	- 기존 명령어 입력 방식 배제, 원클릭 실행 파일 도입 - 불안정한 웹 로딩 대신 로컬 폴더 이미지를 활용하도록 접근성과 구동 안정성 향상

콘텐츠 개발 구성 결과

본 연구에서 개발한 콘텐츠는 배치(bat) 형식을 기반으로 한 웹 앱 실행파일, 은하 이미지 데이터 폴더, 학습 활동지로 구성되며, 연구용 구글 사이트에서 다운로드할 수 있다(그림 2). 실행파일은 필수 라이브러리 설치와 앱 구동을 자동화하도록 프로그램화되어 있어, 별도의 명령어 입력 없이 웹 앱을 손쉽게 실행할 수 있다. 은하 이미지 데이터 폴더에는 은하 유형별로 은하 이미지가 분류되어 있으며, 사용자가 자유롭게 새로운 이미지를 추가하거나 기존 이미지를 교체할 수 있다.

문제 정의 단계에서는 육안 분류와 AI 기반 분류의 차이를 비교하고, 딥러닝을 활용한 은하 분류를 수행하기 위해 필요한 데이터 준비 전략을 설정하도록 하였다(그림 3). 이 단계에서는 은하 분류가 단순한 정답 확인 활동이 아니라, 데이터 조건과 분석 방법에 따라 결과가 달라질 수 있는 탐구 문제임을 확인하도록 하였다.

데이터 수집 단계에서는 은하 이미지의 유형, 출처, 수집 조건을 확인하도록 하였다(그림 4). 실습에서는 NED와 CDS Portal을 활용하여 타원 은하 117개, 렌즈 은하 104개, 정상 나선 은하 123개, 막대 나선 은하 123개, 불규칙 은하 81개 등 총 548개의 이미지를 확보하도록 구성하였다. 수집 후에는 유형별 이미지 수와 데이터 구성을 요약 결과로 확인하도록 하였다.

데이터 처리 및 탐색 단계에서는 이미지 크기 표준화, 컬러-흑백 변환, 회전 및 대칭 증강을 선택할 수 있도록 하였다(그림 5). 이미지 크기는 50×50 픽셀로 표준화하였으며, 회전은 0°부터 315°까지 45° 간격으로 적용하고, 좌우 대칭을 함께 적용할 경우 최대 16배까지 데이터가 증강되도록 구성하였다. 이 기능은 학습자가 데이터 증강 전후의 이미지 변화를 확인하고, 은하가 하늘 평면상에서 다양한 방향으로 관측될 수 있다는 조건을 데이터 처리 과정과 연결하여 살펴볼 수 있도록 하기 위한 것이다. 처리 결과는 실시간 시각화와 요약 결과로 제시하였다.



(1) '은하 분류 AI 실습키트' 저장 웹사이트

이름	수정된 날짜	유형	크기
은하분류 AI 앱 실행 설명서	2026-05-14 오후 11:37	텍스트 문서	4KB
실행하기	2026-05-05 오후 3:31	Windows 배치 파일	3KB
딥러닝 은하 분류 활동지	2026-01-23 오전 2:20	한컴오피스 한글 ...	66KB
utils	2026-05-07 오전 2:05	JetBrains PyChar...	13KB
ui	2026-05-13 오전 2:03	JetBrains PyChar...	33KB
main	2026-05-05 오후 3:42	JetBrains PyChar...	4KB
guides	2026-05-13 오전 12:46	JetBrains PyChar...	17KB
contents	2026-05-13 오전 12:53	JetBrains PyChar...	27KB
galaxy_me	2026-05-10 오후 11:38	파일 폴더	
__pycache__	2026-05-13 오전 2:03	파일 폴더	

(2) '은하 분류 AI 실습키트' 구성파일

그림 2. 콘텐츠 파일 구성. (1) 연구용 구글 사이트에서 '은하 분류 AI 실습키트' 다운로드. (2) 실행하기 파일 실행.

(A) 학습 목표

1. (지구과학) 관측 데이터의 특성과 채우마주 분류의 조건성 이해하기
2. (디지털 탐구 도구(AI)) 대규모 데이터 처리를 위한 지능형 분석 도구의 필요성 인식하기
3. (데이터 리터러시) 탐구 질문에 따라 데이터 분석 계획 수립하기

탐구 질문 및 힌트 열기

Q1. 사람의 눈으로 구분하기 어려운 은하들을 더 정확하게 나누려면 어떤 방법이 좋을까요?

힌트 보기 (질문1)

(힌트1) 사람이 은하를 볼 때, 어떤 점이 헛갈릴 수 있을까요?

(힌트2) 사람이 놓치기 쉬운 부분을 컴퓨터는 어떻게 처리할 수 있을까요?

Q2. 천문학자들은 은하를 어떻게 분류할까요? 직접 관찰을 통해 분류하는 방식과 딥러닝을 이용한 자동 분류 방식은 어떤 점이 다를까요?

힌트 보기 (질문2)

(힌트1) 사람은 눈으로 보면서 은하의 모양을 어떻게 구분할까요?

(힌트2) 딥러닝은 눈 대신 무엇을 이용해서 분류할까요?

(힌트3) 사람과 컴퓨터는 실수하는 방식이 어떻게 다를까요?

Q3. 딥러닝 모델을 훈련시키기 위해서는 어떤 방식으로 은하 이미지 데이터를 준비해야 할까요?

힌트 보기 (질문3)

(힌트1) 이미지의 크기나 개수는 딥러닝이 학습할 때 어떤 영향을 줄까요?

(힌트2) 컴퓨터가 '이건 어떤 은하이다'라고 배우려면 어떤 식으로 알려줘야 할까요?

(B)

[Q1]

- 사람은 눈으로 은하의 모양을 보고 분류하지만, 어떤 은하는 모양이 애매하거나 흐려서 헛갈릴 수 있습니다.
- 이럴 때는 딥러닝 같은 인공지능 기술을 사용하면, 컴퓨터가 이미지 속의 미세한 특징들을 스스로 찾아내서 분류할 수 있습니다.
- 즉, 사람이 놓치는 작은 차이도 컴퓨터는 수많은 데이터를 학습하면서 구분할 수 있습니다.

[Q2]

- 천문학자들은 주로 망원경으로 촬영한 은하 이미지를 보고, 모양이나 구조를 두으로 관찰해서 분류합니다.
- 반면에 딥러닝은 이미지 속 숫자 정보(픽셀값)를 바탕으로 패턴을 스스로 학습해서 분류합니다.
- 사람은 관찰과 직관을 사용해서 빠르게 판단할 수 있지만, 감정이나 피로에 따라 실수할 수 있습니다.
- 딥러닝은 항상 같은 방식으로 많은 데이터를 처리할 수 있지만, 훈련이 잘못되면 일정한 실수를 할 수도 있기에, 두 방식은 서로 보완이 필요합니다.

[Q3]

- 딥러닝이 잘 학습하려면, 이미지 (1) 모든 은하 이미지의 크기를 같은 맞춰줘야 합니다.
- 크기가 제각각이면 컴퓨터가 혼란스러워할 수 있습니다.
- 그리고 (2) 다양한 은하 종류의 이미지를 골고루 넣어 주어야 합니다.
- 머플 들어, 타원 은하 이미지만 많고 다른 은하 이미지가 너무 적으면, 모델이 타원 은하만 잘 맞히고 나머지는 자주 틀릴 수 있습니다.
- 또한, 각 이미지가 (3) 어떤 은하인지 이름(레이블)을 붙여주는 작업도 꼭 필요합니다.
- 그래야 컴퓨터가 "아, 이런 다윈 은하였구나!" 하면서 배울 수 있습니다.

그림 3. 문제 정의 단계. (A) 웹 앱 생각해보기의 질문 및 힌트 화면, (B) 웹 앱 생각해보기의 답변 화면.

데이터 분석 및 표현 단계에서는 CNN 기반 모델을 구성하고, 학습 결과를 성능 지표와 시각화 자료로 확인하도록 하였다(그림 6). 학습자는 훈련·검증·테스트 데이터 비율을 설정하고, 합성곱 레이어, 필터 수, 풀링 크기, 학습률 등 주요 하이퍼파라미터를 조정할 수 있다. 학습 과정에서는 에포크별 정확도와 손실 값의 변화를 확인하고, 학습 완료 후에는 훈련·검증·테스트 데이터의 분류 결과, 혼동행렬, 오분류 이미지를 확인하도록 구성하였다. 이를 통해 전체 정확도뿐 아니라 어떤 은하 유형 사이에서 분류 혼동이 발생하는지 검토할 수 있도록 하였다.

학습 활동지의 데이터 분석 실험은 필수 탐구와 심화 선택 탐구로 구분하였다(그림 7). 필수 탐구에는 데이터 증강 효과 실험과 학습률 효과 실험을 포함하였다. 데이터 증강 효과 실험에서는 증강 여부에 따른 정확도와 손실 값의 변화를 비교

(A) 2단계: 데이터 수집

학습 목표

1. (지구과학) 허블 분류 체계에 따른 은하의 형태학적 기준 파악하기
2. (디지털 탐구 도구(AI)) 신뢰할 수 있는 천문 빅데이터(NED, SDSS, DSS) 접근 및 확보하기
3. (데이터 리터러시) 데이터 출처 신뢰성 및 적절성을 평가하며 데이터 수집하기

탐구 질문 및 힌트 열기

Q1. 은하를 딥러닝으로 분류하려면 어떤 종류의 은하 이미지가 필요할까요?

힌트 보기 (질문1)

Q2. 은하 이미지는 어디에서 구할 수 있을까요?

힌트 보기 (질문2)

Q3. 은하 이미지를 수집할 때, 어떤 점에 주의해야 할까요?

힌트 보기 (질문3)

모범 답안 보기

(B)

1. 수집하고 싶은 은하 유형을 선택합니다.
2. 수집하고 싶은 이미지의 번호를 입력합니다.
3. "이미지 수집" 버튼을 클릭하여 선택한 이미지를 수집합니다.
4. 수집된 이미지가 화면에 표시됩니다.

※ TIP! 본 실험에서는 모든 은하 데이터를 수집합니다. 이미지를 한 번에 모두 수집하고 싶으면, 이미지1-이미지200 이라고 입력하면 됩니다.

Elliptical Galaxy 데이터 수집 중...

이미지 번호 입력

예: 이미지1-이미지10, 이미지15

Elliptical Galaxy 이미지 수집

Elliptical Galaxy 폴더의 전체 이미지

IC_1459_E3_DSS.png	M_105_E1_DSS.png	M_49_E2_DSS.png	M_59_E5_DSS.png	NGC_1052_E4_DSS.png
NGC_1132_E_DSS.png	NGC_1199_E3_DSS.png	NGC_1270_E_DSS.png	NGC_1274_E3_DSS.png	NGC_1278_E_DSS.png

그림 4. 데이터 수집 단계. (A) 웹 앱 생각해보기 화면, (B) 웹 앱 은하 이미지 수집 실시 화면.




그림 5. 데이터 처리 및 탐색 단계. (A) 웹 앱 생각해보기 화면. (B) 웹 앱 은하 처리 및 탐색 실시 화면.

하도록 하였고, 학습을 효과 실험에서는 학습을 조건에 따른 모델 성능 변화를 확인하도록 하였다. 심화 선택 탐구에는 모델 파라미터 규모 효과 실험과 최대 풀링 크기 효과 실험을 포함하여, 모델 구조 변화가 학습 결과와 연산 과정에 미치는 영향을 추가로 탐색할 수 있도록 하였다.

일반화 단계에서는 전체 탐구 과정을 종합하여 분류 결과의 신뢰성과 한계를 정리하도록 하였다(그림 8). 학습자는 전체 정확도만 제시하는 것이 아니라, 혼동행렬과 오분류 이미지 사례를 근거로 분류 결과를 검토하도록 하였다. 특히 오분류 사례에서는 은하의 중심부, 막대 구조, 나선팔, 외곽 윤곽 등 형태학적 특징과 이미지 해상도 조건을 함께 고려하여 분류 오류의 가능성을 해석하도록 구성하였다. 또한 데이터 출처 명시와 자료 활용에 관한 데이터 윤리 요소를 확인하고, 본 탐구 절차를 다른 천문 자료 또는 자연 현상 자료 분석으로 확장할 수 있는 가능성을 논의하도록 하였다.

결론 및 제언

본 연구는 고등학교 지구과학 교육과정의 은하 분류 단원을 중심으로, AI를 은하의 형태학적 특징과 분류 결과를 해석하는 탐구 도구로 설정함으로써, 학생들이 은하의 관측적 특징을 보다 세밀하게 관찰하고 해석할 수 있는 교육적 가능성을 탐색하는 데 목적을 두었다. 이를 위해 실제 천문학 연구 절차를 반영한 데이터 사이언스·딥러닝 기반 교육 콘텐츠를 개발하고, 교사가 수업에서 활용할 수 있는 형태로 그 적용 가능성을 검토하였다. 구체적으로 5개 유형의 은하 이미지 데이터를 수집·처리하고, 회전 및 대칭 증강, CNN 기반 분류, 혼동행렬 및 오분류 사례 분석을 포함한 웹 앱과 활동지를 구성하였으며, 성능검증과 전문가 파일럿 테스트를 통해 콘텐츠의 수업 적용 가능성과 보완점을 확인하였다. 이와 관련하여 본 연구의 시사점은 다음과 같다.

첫째, 본 연구는 딥러닝 기반 은하 분류의 성능 개선을 목적으로 하는 천문학·우주과학 분야의 전문 연구와 달리, 해당 연구 절차를 고등학교 지구과학 교육의 탐구 활동으로 재구성하였다. 천문학·우주과학 분야의 딥러닝 은하 분류 연구는 대규모 관측 자료의 자동 분류와 정확도 향상에 초점을 두어 왔다(Chauhan & Singh, 2018; Gharat & Dandawate, 2022; Wu et al., 2022). 반면 본 연구는 데이터 수집, 전처리, 데이터 증강, CNN 분류, 혼동행렬 해석을 수업 단계에 반영하여, 학습자가 AI 산출물을 정답으로 수용하지 않고 관측 자료의 해상도, 은하의 형태학적 특징, 오분류 원인을 지구과학적 근거에 따라 해석하도록 하였다. 이는 기존 교육과정의 단순 이미지 비교 중심 활동 및 블랙박스형 AI 결과 확인 중심

(A)

● 학습 목표

1. [지구과학] 은하의 세부구조(중심부핵, 막대, 나선팔 등)의 시각적 특징 정밀 식별하기
2. [다지탈 탐구 도구(AI)] CNN 모델을 활용한 특징 추출 및 성능 지표(혼동행렬 등) 도출하기
3. [데이터 리터러시] 데이터 표현, 데이터 평가, 데이터 기반 의사결정, 데이터 도구 활용의 효과성에 기반하여, 성능 지표에 기반한 분류 결과의 타당성 및 오분류 원인 진단하기

 탐구 질문 및 힌트 열기

Q1. 합성곱 신경망(CNN)은 어떤 기술인가요? 왜 이미지 분류에 잘 쓰일까요?

☐ 힌트 보기 (질문1)

Q2. 딥러닝 모델의 성능을 높이기 위해 어떤 설정값(학습률, 레이어(층) 수 등)을 조절할 수 있을까요? 왜 그게 중요할까요?

☐ 힌트 보기 (질문2)

Q3. 혼동행렬, 정확도, 정밀도, 재현율, F1 점수, 손실값 같은 평가 지표들은 각각 어떤 의미이고, 모델의 성능을 어떻게 판단할 수 있을까요?

☐ 힌트 보기 (질문3)

Q4. 딥러닝 모델이 잘못 분류하는 은하는 어떤 특징을 가지고 있나요?

☐ 힌트 보기 (질문4)

  모범 답안 보기

(C)

[전반부] 특징 추출기(CNN)

Diagram illustrating the architecture of a neural network with 10 layers. The layers are defined by their input/output dimensions, filters, kernel size, and activation function.

Layer	Input/Output Dimensions	Filters	Kernel Size	Activation Function
1	28x28x3	-	-	-
2	32x32x3	32	3x3	ReLU
3	64x64x3	64	3x3	ReLU
4	64x64x3	64	3x3	ReLU
5	128x128x3	128	3x3	ReLU
6	128x128x3	128	3x3	ReLU
7	256x256x3	256	3x3	ReLU
8	256x256x3	256	3x3	ReLU
9	512x512x3	512	3x3	ReLU
10	512x512x3	512	3x3	ReLU

2. 모델 구성

모델 레이어 요약

	레이아웃 이름	레이아웃 설명	수익 형태	피리미트 수
3	max_pooling2d	MaxPooling2D	15 25 32	0
4	conv2d_1	Conv2D	25 25 64	18496
5	batch_normalization_1	Batch Normalization	25 25 64	256
6	activation_1	Activation	25 25 64	
7	max_pooling2d_1	MaxPooling2D	13 13 64	0
8	conv2d_2	Conv2D	13 13 128	73856
9	batch_normalization_2	Batch Normalization	13 13 128	512
10	activation_2	Activation	13 13 128	0
11	max_pooling2d_2	MaxPooling2D	7 7 128	0
12	global_average_pooling2d	GlobalAveragePooling2D	128	0

(B)

1. 데이터셋 분할



(E)

	Epoch	LR	Train Loss	Train Acc	Val Loss	Val Acc
0	1	0.001	4.3546	0.5925	2.7889	0.1636
1	2	0.001	1.3960	0.6113	2.1475	0.2909
2	3	0.001	1.1397	0.6253	1.9933	0.3636
3	4	0.001	1.1434	0.6259	4.3368	0.1455
4	5	0.001	1.1021	0.6388	2.4381	0.3636
5	6	0.001	1.0863	0.6461	2.5956	0.4000
6	7	0.0010000005	0.9088	0.7109	1.0233	0.6182
7	8	0.0010000005	0.8219	0.7416	0.9820	0.6364
8	9	0.0010000005	0.7749	0.7567	1.0336	0.6545
9	10	0.0010000005	0.7363	0.7767	0.9723	0.7091

그림 6. 데이터 분석 단계. (A) 웹 앱 생각해보기 화면. (B) 웹 앱 훈련·검증·테스트 데이터 분할 화면. (C) 앱 하이퍼파라미터 조정 화면. (D) 웹 앱 모델 레이어 및 파라미터 정보 화면. (E) 웹 앱 모델 훈련 진행 결과 화면.

현장과학교교육 권(호)

(A)

- 실험 방법
- ★ 비교 옵션 사항
 - 모델 A: 데이터 증강 X (훈련 데이터 증강 미적용)
 - 모델 B: 데이터 증강 O (훈련 데이터에만 비선형 학습 대상 증강 적용)

- ★ 비교 결과 사항
 - 훈련시간, 정확도, 손실값

★ 3-4-5단계 모델 옵션 설정 방법

모델 유형	A	B
3-4단계	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 X	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O
5단계	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001

㉠ 테스트 데이터 결과 기록

모델	데이터 증강	훈련 시간(초)	정확도(Accuracy)	손실값(Loss)
모델 A	X (미적용)			
모델 B	O (적용)			

㉡ 질문1: 데이터 증강을 하지 않은 모델과 비교했을 때, 성능 차이가 있나? 그 이유는 무엇이라고 생각하나요?

㉢ 질문2: 데이터 증강이 과적합을 줄이는 데 어떤 도움을 줄 수 있을까요?

(C)

- 실험 방법
- ★ 비교 옵션 사항
 - 모델 A: 전방부 합성곱 레이어 3개 (8-16-32)
 - 후방부 완전 연결 레이어: 2개 (32-16)
 - 모델 B: 전방부 합성곱 레이어 3개 (32-64-128)
 - 후방부 완전 연결 레이어: 2개 (128-64)

- ★ 비교 결과 사항
 - 훈련시간, 정확도, 손실값

★ 3-4-5단계 모델 옵션 설정 방법

모델 유형	A	B
3-4단계	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O
5단계	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (8-16-32) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (32-16) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001

㉠ 테스트 데이터 결과 기록

모델	합성곱 필터 수, 완전 연결 노드 수	훈련 시간(초)	정확도(Accuracy)	손실값(Loss)
모델 A	합성곱 3개 (8-16-32), 완전 연결 2개 (32-16)			
모델 B	합성곱 3개 (32-64-128), 완전 연결 2개 (128-64)			

㉡ 질문1: 합성곱 필터 및 완전 연결 노드 수가 증가할수록 훈련 시간과 정확도, 손실값에 어떤 변화가 있었나요?

㉢ 질문2: 모델의 파라미터 수가 많아지고 항상 분류 성능이 좋아질까요? 그 이유는 무엇일까요?

(B)

- 실험 방법
- ★ 비교 옵션 사항
 - 모델 C: 학습률 0.01
 - 모델 D: 학습률 0.001

- 모델 B: 학습률 0.0001
- ★ 비교 결과 사항
 - 훈련시간, 정확도, 손실값

★ 3-4-5단계 모델 옵션 설정 방법

모델 유형	C	D	E
3-4단계	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O
5단계	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.01	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.0001

㉠ 테스트 데이터 결과 기록

모델	학습률	훈련 시간(초)	정확도(Accuracy)	손실값(Loss)
모델 C	0.01			
모델 D	0.001			
모델 E	0.0001			

㉡ 질문1: 학습률을 낮출수록 훈련 시간과 정확도, 손실값에 어떤 변화가 있었나요? 그 이유는 무엇일까요?

㉢ 질문2: 학습률을 정말 꽤 어떤 것을 고려해야 무엇이 잘 될 수 있을까요?

(D)

- 실험 방법
- ★ 비교 옵션 사항
 - 모델 C: 최대 풀링 2x2
 - 모델 D: 최대 풀링 4x4

- ★ 비교 결과 사항
 - 훈련시간, 정확도, 손실값

★ 3-4-5단계 모델 옵션 설정 방법

모델 유형	C	D
3-4단계	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O	• 이미지 표준화 O • 컬러 이미지 처리 O • 데이터 증강 O
5단계	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 2 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001	• 훈련 데이터 비율: 80% • 검증 데이터 비율: 10% • 테스트 데이터 비율: 10% • 전방부 합성곱 레이어 수: 3개 (32-64-128) • 최대 풀링: 4 • 전방부 활성화 함수: relu • 드롭아웃: 0개 • 드롭아웃 비율: 0.0 • 후방부 완전 연결 레이어: 2개 (128-64) • 후방부 완전 연결 레이어 활성화 함수: relu • 마지막 완전 연결 레이어 활성화 함수: softmax • 배치 크기: 16개 • 에포크 수: 100개 • 학습률: 0.001

㉠ 테스트 데이터 결과 기록

모델	최대 풀링 크기	훈련 시간(초)	정확도(Accuracy)	손실값(Loss)
모델 C	2x2			
모델 D	4x4			

㉡ 질문1: 최대 풀링 크기가 커질수록 훈련 시간과 정확도, 손실값에 어떤 변화가 있었나요? 그 이유는 무엇일까요?

㉢ 질문2: 어떤 상황에서 큰 풀링이 도움이 되고, 어떤 상황에서는 문제가 될 수 있을까요?

그림 7. 데이터 분석 활동지. (A) 필수 탐구, 데이터 증강 효과 실험. (B) 필수 탐구, 학습률 효과 실험. (C) 선택 탐구 - 모델 파라미터 규모 효과 실험. (D) 선택 탐구 - 최대 풀링 크기 효과 실험.



그림 8. 일반화 단계. (A) 웹 앱 생각해보기의 질문 화면. (B) 웹 앱 생각해보기의 답변 화면.

활동과 구별된다(문우중 외, 2023; 신요한, 2022; Billingsley et al., 2022; Hart et al., 2016; Raddick et al., 2019).

둘째, 본 연구는 기존의 컴퓨터 활용 은하 분류 연구가 충분히 다루지 못한 데이터 사이언스 절차를 은하 분류 수업의 학습 흐름으로 구조화하였다. 선행연구에서는 컴퓨터 기반 은하 분류, 시민과학 기반 분류, 파이썬 기반 이미지 분석 등이 시도되었으나(조훈과 손정주, 2022b; Borne, 2009; Borne, 2010; Hart et al., 2016; Raddick et al., 2019), 교육적 맥락에서 데이터 사이언스 전 과정을 체계적으로 경험하도록 구성한 사례는 제한적이었다(조연수, 2022). 본 연구는 이 한계를 보완하기 위해 은하 이미지의 수집, 크기 표준화, 회전 및 대칭 증강, CNN 기반 분류, 혼동행렬 해석을 하나의 수업 절차로 연결하였다. 특히 데이터 증강은 은하가 하늘 평면상에서 다양한 방향으로 관측되는 조건을 반영한 활동으로 구성하여, 학습자가 회전 및 대칭 처리를 단순한 성능 향상 기법이 아니라 관측 조건과 관련된 데이터 처리 과정으로 이해하도록 하였다.

셋째, 본 연구는 AI 분류 결과의 해석 과정을 통해 데이터 리터러시를 구체적인 학습 활동으로 구현하였다. 데이터 리터러시는 실제적 맥락에서 데이터를 해석하고 평가하는 능력을 포함하며(Kjelvik & Schultheis, 2019), 과학 수업에서 데이터 수집, 분석, 표현, 평가를 연결하는 탐구 경험과 관련된다(Calzada-Prado & Marzal, 2013; Ceccucci et al., 2015). 본 연구에서 학습자는 은하 유형과 데이터 출처를 확인하고, 이미지 표준화와 증강을 수행하며, 정확도, 손실 값, 혼동행렬, 오분류 이미지를 근거로 모델의 결과를 해석하였다. 특히 오분류 사례는 모델의 오류로만 제시되지 않고, 이미지 해상도 저하에 따른 막대 구조, 나선팔, 외곽 윤곽의 식별 문제와 연결하여 해석하도록 하였다. 이는 AI 활용 수업에서 결과값의 확인보다 데이터 조건과 해석 근거를 함께 다루어야 함을 시사한다.

넷째, 본 연구에서 개발한 Streamlit 기반 웹 앱과 활동지는 교사의 수업 적용 가능성을 고려하여 설계되었다. 기존 연구에서는 교사들이 AI 활용 교육을 부담으로 인식하거나, 딥러닝 학습 과정이 과학 교과와의 범주를 벗어난 컴퓨터공학 영역으로 간주되는 문제가 있다고 보고하였다(문우중 외, 2023; 문현우와 이영준, 2024; 신요한, 2022). 본 연구는 이러한 문제를 고려하여 문제 정의, 데이터 수집, 처리, 탐색, 분석, 일반화 단계를 탭 이동과 선택 기능으로 수행하도록 구성하고, 활동지를 필수 탐구와 심화 선택 탐구로 구분하였다. 또한 로컬 이미지 폴더와 배치 형식의 실행파일을 활용하도록 보완하여, 프로그래밍 지식이 부족한 교사와 학습자도 콘텐츠를 활용할 수 있도록 하였다. 이러한 구성은 2022 개정 교육과정에서 강조하는 빅데이터 및 AI 활용 탐구를 지구과학 수업에서 구현하기 위한 하나의 개발 사례가 된다(교육부, 2022).

본 연구의 제한점과 제언은 다음과 같다.

본 연구는 전문가 검토를 중심으로 콘텐츠의 수업 적용 가능성을 살펴본 개발 연구로, 실제 학생을 대상으로 한 수업 적용 및 학습 효과 검증은 수행하지 않았다. 또한 전문가 수가 제한적이며, 548개의 은하 이미지와 50×50 픽셀의 입력 이미지를 활용하였다는 점에서 데이터 규모와 세부 형태 정보의 표현에 한계가 있다. 아울러 성능검증은 CPU 기반의 로컬 PC 환경에서 수행되었으므로, 다양한 학교 수업 환경에서의 적용 가능성을 확인하기 위한 후속 검토가 필요하다.

이러한 제한점을 바탕으로 후속 연구에서는 실제 학생을 대상으로 콘텐츠를 적용하여 데이터 기반 탐구 과정과 학습자의 반응을 검토할 필요가 있다. 또한 보다 다양한 은하 이미지와 입력 해상도, 학교 컴퓨터 환경을 적용하여 콘텐츠의 수업 활용 가능성과 기술적 안정성을 추가로 확인할 필요가 있다.

참고문헌

- 교육부 (2015) 교육부 고시 제2015-74호[별책 9] 과학과 교육과정. 교육부.
- 교육부 (2022) 교육부 고시 제2022-33호[별책 9] 과학과 교육과정. 교육부.
- 교육부, 한국과학창의재단 (2021) (중학교) 학교에서 만나는 인공지능 수업. 교육부와 한국과학창의재단.
- 구덕희, 김동진 (2020) 문제 해결 학습 모형 기반의 데이터 과학 교육 프로그램 개발. 한국초등교육 31: 203-215.
- 김용민, 김종훈 (2017) 스프레드시트를 활용한 데이터 과학 교육 프로그램이 초등학생의 컴퓨팅 사고력 향상에 미치는 효과. 정보교육학회논문지 21(2): 219-230.
- 김재경, 손의성 (2021) 비전공자 대상의 데이터과학 교과목 개발과 컴퓨팅 사고력 효과 분석. 컴퓨터교육학회 논문지 24(3): 23-31.
- 김주은 (2019) 인공지능이 인간사회에 미치는 영향에 대한 연구. 문화기술의 융합 5(2): 177-182.
- 김태영, 김철민, 윤혜경 (2020) 교양강좌로서 데이터 리터러시 가능성 탐색. Journal of The Korean Data Analysis Society 22(6): 2475-2487.
- 김화중 (2014) 데이터 사이언스 개론. 흥릉과학출판사.
- 문우중, 김보솔, 고승환, 고은정, 김종훈 (2023) 딥러닝 원리 중심의 인공지능 교육 프로그램 개발 및 적용. 한국정보교육학회 학술논문집 14(1): 123-128.
- 문현우, 이영준 (2024) 데이터 리터러시 기반 SW융합교육이 초등학생의 컴퓨팅 사고력에 미치는 효과. 컴퓨터교육학회 논문지 27(4): 247-259.
- 배화순 (2019) 데이터 리터러시의 사회화 교육적 함의. 시민교육연구 51(1): 95-120.
- 서용, 안성진 (2022) 학생들의 데이터과학에 대한 태도 요인 제안. 한국컴퓨터교육학회 학술발표대회논문집 26(2): 111-113.
- 신요한 (2022) 대학 신입생 대상 코딩 교육 및 인공지능 교육 현황과 시사점. 교양교육연구 16(1): 11-23.
- 양병화 (2013) 심리학 및 사회과학을 위한 조사와 통계 분석. 학지사.
- 오필석, 문병권, 소영무, 전해진, 박찬경, 안인수 (2024) 고등학교 지구과학. 천재교과서.
- 이기영, 김형수, 김신애, 백명희, 윤병일, 정재훈 (2024) 고등학교 지구과학. 비상교육.
- 이지훈, 신지은 (2024) 인공지능 학습데이터 라벨링 정확도에 따른 인공지능 성능. 산업융합연구 22(1): 177-183.
- 정운숙, 유지원 (2022) 대학생의 데이터 리터러시 측정 도구 타당화 및 신입생 데이터 리터러시 진단-A 대학 사례를 중심으로. 교양교육연구 16(5): 245-260.

- 조연수 (2022) 인공지능을 융합한 과학 수업이 중학생들의 인공지능에 대한 태도 및 데이터 리터러시 역량에 미치는 효과. 이화여자대학교 대학원 석사학위논문.
- 조훈, 손정주 (2022a) 고등학교 천문학 수업에서 코딩을 활용한 데이터 기반 탐구활동의 활성화 방안 탐색. 현장과학교육 16(5): 602-618.
- 조훈, 손정주 (2022b) 외부고리 은하 영상 분석을 위한 파이썬 기반 알고리즘 개발. 한국지구과학회지 43(5): 579-590.
- 조훈, 손정주 (2025) 태양계 천체의 역학적 분류를 위한 데이터 사이언스 기반 천문 교육 콘텐츠 개발. 현장과학교육 19(5): 412-437.
- 최경희, 조동성 (2023) 확장된 데이터의 특성과 맥락을 반영한 데이터 리터러시의 재개념화. 정보화정책 30(3): 49-68.
- 하수옥, 정의현 (2020) 데이터 분석 및 머신러닝을 위한 데이터 품질 표준화. TTA 저널 192: 22-27.
- 한상우 (2020) 인문학 기반 데이터 리터러시 모형 설계에 관한 연구. 정보관리학회지 37(1): 179-195.
- 한신, 김형범 (2019) 블록형 코딩프로그램을 활용한 지구과학 수업에서 학생들의 컴퓨팅 사고력에 대한 인식 및 과학적 태도 변화 연구. 대한지구과학교육학회지 12(2): 131-140.
- Athanases SZ, Bennett LH & Wahleithner JM (2013) Fostering data literacy through preservice teacher inquiry in English language arts. The Teacher Educator 48(1): 8-28.
- Billingsley B, Heyes JM, Lesworth T & Sarzi M (2022) Can a robot be a scientist? Developing students' epistemic insight through a lesson exploring the role of human creativity in astronomy. Physics Education 58(1): 1-10.
- Borne KD (2009) Astrominformatics: a 21st century approach to astronomy. Astro2010: The Astronomy and Astrophysics Decadal Survey, Position Papers 6.
- Borne KD (2010) Astrominformatics: data-oriented astronomy research and education. Earth Science Informatics 3: 5-17.
- Buta R (2013) Galaxy morphology. In: Oswalt TD and Keel WC (Eds.), Planets, Stars and Stellar Systems, Volume 6: Extragalactic Astronomy and Cosmology. Springer Dordrecht. pp 1-89.
- Calzada-Prado J & Marzal MÁ (2013) Incorporating data literacy into information literacy programs: core competencies and contents. Libri 63(2): 123-134.
- Ceccucci W, Tamarkin D & Jones K (2015) The effectiveness of data science as a means to achieve proficiency in scientific literacy. Information Systems Education Journal 13: 64-70.
- Chauhan G & Singh AK (2018) Machine learning classification of stars, galaxies, and quasars. MATTER: International Journal of Science and Technology 4(3): 152-167.
- Cleveland WS (2001) Data science: an action plan for expanding the technical areas of the field of statistics. International Statistical Review 69(1): 21-26.
- de Vaucouleurs G (1963) Revised classification of galaxies for the first reference catalogue. The Astrophysical Journal Supplement Series 8: 31.
- Dhar V (2013) Data science and prediction. Communications of the ACM 56(12): 64-73.
- Dieleman S, Willett KW & Dambre J (2015) Rotation-invariant convolutional neural networks for galaxy morphology prediction. Monthly Notices of the Royal Astronomical Society 450(2): 1441-1459.
- Duschl RA (2008) Science education in three-part harmony: balancing conceptual, epistemic, and social learning goals. Review of Research in Education 32(1): 268-291.
- Gharat S & Dandawate Y (2022) Galaxy classification: a deep learning approach for classifying Sloan Digital Sky Survey images. Monthly Notices of the Royal Astronomical Society 511(4): 5120-5124.

- Hart RE, Bamford SP, Willett KW, Masters KL, Cardamone C, Lintott CJ, Mackay RJ, Nichol RC, Rosslowe CK, Simmons BD & Smethurst RJ (2016) Galaxy Zoo: comparing the demographics of spiral arm number and a new method for correcting redshift bias. *Monthly Notices of the Royal Astronomical Society* 461(4): 3663-3682.
- Herzog D (2016) *Data Literacy: A User's Guide*. SAGE.
- Hubble EP (1936) *The Realm of the Nebulae*. New Haven: Yale University Press.
- Kjelvik MK & Schultheis EH (2019) Getting messy with authentic data: exploring the potential of using data from scientific research to support student data literacy. *CBE-Life Sciences Education* 18(2): 1-8.
- Lehrer R & Schauble L (2006) Scientific thinking and science literacy. *Handbook of Child Psychology* 4: 153-196.
- Mickaelian AM (2018) Astroinformatics and astrostatistics. *Communications of the Byurakan Astrophysical Observatory* 65(1): 1-13.
- National Research Council (NRC) (2012) *A Framework for K-12 Science Education: Practices, Crosscutting Concepts, and Core Ideas*. Washington, DC: National Academies Press.
- Nielsen J (1994) *Usability Engineering*. Morgan Kaufmann.
- Raddick MJ, Prather EE & Wallace CS (2019) Galaxy zoo: science content knowledge of citizen scientists. *Public Understanding of Science* 28(6): 636-651.
- Rodríguez JV, Rodríguez-Rodríguez I & Woo WL (2022) On the application of machine learning in astronomy and astrophysics: a text-mining-based scientometric analysis. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 12(5): 1-32.
- Tukey JW (1977) *Exploratory Data Analysis*. Reading, Mass.: Addison-Wesley Pub. Co. pp 5-23.
- Wu D, Zhang J, Li X & Li H (2022) A lightweight deep learning framework for galaxy morphology classification. *Research in Astronomy and Astrophysics* 22(11): 115011.